

ANEXO 13

BENCHMARK COMERCIAL DEL FRAMEWORK DE INTEROPERABILIDAD PARA LA GESTIÓN HÍDRICA

Comparación funcional con plataformas comerciales de Ciencia de Datos y Machine Learning

Capa de Validación Profesional del Framework (CVPF)
Correspondencia documental: Anexo F

José Daniel Barreto · Juan Carlos Riatiga Peña

Maestría en Ciencia de Datos · Universidad Autónoma de Bucaramanga - UNAB

2026

Control documental

Código documental	CVPF-BENCH-001
Nombre	Benchmark Comercial del Framework de Interoperabilidad para la Gestión Hídrica
Versión	1.0
Estado	Documento complementario de validación profesional
Autores	José Daniel Barreto y Juan Carlos Riatiga Peña
Programa	Maestría en Ciencia de Datos
Institución	Universidad Autónoma de Bucaramanga - UNAB
Fecha de corte documental	5 de agosto de 2026

Contenido del anexo

- F.0 Introducción y criterio de interpretación
- F.1 Objetivo
- F.2 Alcance
- F.3 Plataformas consideradas
- F.4 Criterios de comparación
- F.5 Benchmark funcional
- F.6 Análisis comparativo
- F.7 Diferenciadores del Framework
- F.8 Limitaciones de la comparación
- F.9 Conclusión
- Documentos base del anexo

F.0 Introducción y criterio de interpretación

El presente benchmark constituye un artefacto documental de la Capa de Validación Profesional del Framework (CVPF). Su finalidad es situar el Framework desarrollado frente a plataformas comerciales de propósito general, sin modificar los resultados de la investigación ni presentar la comparación como una prueba de superioridad tecnológica.

La comparación se elaboró a partir de la arquitectura implementada en la investigación y de funcionalidades descritas en documentación oficial de los fabricantes. Debido a que las plataformas comerciales evolucionan continuamente, los resultados deben interpretarse como una fotografía funcional correspondiente a la fecha de corte documental indicada.

Criterio de lectura

La expresión “Nativo” indica que la capacidad está documentada como parte de la plataforma o de sus módulos oficiales. “Config.” señala que la capacidad puede implementarse mediante servicios complementarios, componentes, flujos o configuración adicional. “No específico” indica que no se identificó un equivalente directo con la misma finalidad metodológica o de dominio. “Propio” identifica una contribución desarrollada en el Framework de la investigación.

F.1 Objetivo

El propósito de este benchmark consiste en comparar las capacidades funcionales del Framework desarrollado durante la investigación con plataformas comerciales ampliamente utilizadas para proyectos de Ciencia de Datos y Aprendizaje Automático.

La comparación no pretende evaluar el desempeño predictivo de los modelos implementados por dichas plataformas, sino identificar diferencias en términos de arquitectura, automatización, interoperabilidad, trazabilidad y orientación al dominio de la gestión hídrica.

F.2 Alcance

El benchmark se realizó considerando funcionalidades documentadas públicamente por los fabricantes y la arquitectura implementada durante esta investigación.

No se ejecutaron experimentos utilizando dichas plataformas. Por tanto, la comparación corresponde exclusivamente a capacidades funcionales documentadas y no incluye rendimiento computacional, precisión predictiva, costos operativos, experiencia de usuario, seguridad empresarial ni escalabilidad bajo cargas reales.

F.3 Plataformas consideradas

Plataforma	Tipo	Enfoque principal
Microsoft Azure Machine Learning	Plataforma comercial Cloud	Ciclo de vida de ML, experimentación, despliegue y monitoreo
Google Vertex AI	Plataforma comercial Cloud	Entrenamiento, experimentación, metadatos, despliegue y MLOps
Amazon SageMaker AI	Plataforma comercial Cloud	Preparación, entrenamiento, registro, despliegue y monitoreo

Plataforma	Tipo	Enfoque principal
DataRobot	Plataforma AutoML comercial	Automatización del modelado, calidad, registro y gobierno de modelos
KNIME Analytics Platform / Business Hub	Plataforma analítica low-code	Integración, análisis, automatización y despliegue de flujos
Framework propuesto	Framework académico de interoperabilidad	Gestión hídrica, integración gobernada, IPML y experimentación reproducible

F.4 Criterios de comparación

La comparación funcional se estructuró en dos grupos: capacidades relacionadas con datos y gobierno, y capacidades relacionadas con experimentación, modelado y especialización del dominio.

- integración de múltiples fuentes de información;
- automatización del proceso ETL;
- gobierno, metadata, auditoría y calidad del dato;
- construcción de un Dataset Maestro;
- análisis exploratorio y preparación de variables;
- selección de variables y conocimiento del dominio;
- diseño y registro experimental;
- interpretación, diagnóstico y recomendaciones;
- orientación específica a la gestión hídrica.

Unidad de análisis

Cada criterio se evaluó en función de su disponibilidad documentada y de su equivalencia con la finalidad metodológica implementada en el Framework. La comparación distingue entre una capacidad nativa, una capacidad que requiere configuración y una capacidad sin equivalente directo de dominio.

Datos y gobierno	Experimentación y modelado	Especialización del dominio
Integración, ETL, metadata, calidad, auditoría y Dataset Maestro	Diseño experimental, registro, interpretación, diagnóstico y recomendaciones	Gestión hídrica, conocimiento experto e IPML

F.5 Benchmark funcional

Nativo	Config.	No específico	Propio
Capacidad documentada como parte de la plataforma	Requiere servicios, módulos, flujos o configuración adicional	No se identificó un equivalente directo con la misma finalidad	Contribución desarrollada en el Framework

F.5.1 Datos, integración y gobierno

Funcionalidad	Framework	Azure ML	Vertex AI	SageMaker	DataRobot	KNIME
Integración de múltiples fuentes	Nativo	Config.	Config.	Nativo / Config.	Nativo / Config.	Nativo
Automatización de ETL y preparación	Nativo	Config.	Config.	Nativo / Config.	Nativo / Config.	Nativo
Gobierno del dato integrado	Nativo	Config.	Config.	Config.	Nativo / Config.	Config.
Dataset Maestro automatizado	Nativo	Config.	Config.	Config.	Config.	Config.
Metadata y linaje	Nativo	Nativo	Nativo	Nativo	Nativo	Config.
Diccionario de datos automático	Nativo	No específico	No específico	No específico	No específico	Config.
Auditoría y trazabilidad del flujo	Nativo	Nativo / Config.	Nativo	Nativo	Nativo	Config.
Indicadores de calidad de datos	Nativo	Nativo / Config.	Nativo / Config.	Nativo / Config.	Nativo	Config.
Análisis exploratorio automatizado	Nativo	Config.	Config.	Nativo / Config.	Nativo	Nativo

F.5.2 Experimentación, modelado y especialización

Funcionalidad	Framework	Azure ML	Vertex AI	SageMaker	DataRobot	KNIME
Índice IPML	Propio	No específico	No específico	No específico	No específico	No específico
Selección basada en conocimiento del dominio	Propio	No específico	No específico	No específico	No específico	Config.
Diseño experimental integrado	Nativo	Nativo / Config.	Nativo	Nativo	Nativo	Config.
Registro automático de experimentos	Nativo	Nativo	Nativo	Nativo	Nativo	Config.
Bitácora experimental y comparación de ejecuciones	Nativo	Nativo	Nativo	Nativo	Nativo	Config.
Interpretación de resultados	Nativo	Nativo / Config.	Nativo / Config.	Nativo / Config.	Nativo	Config.
Diagnóstico automático contextual	Nativo	Config.	Config.	Config.	Nativo / Config.	Config.
Recomendaciones automáticas de mejora	Nativo	No equivalente directo	No equivalente directo	No equivalente directo	Config.	Config.
Orientación específica a gestión hídrica	Nativo	No específico	No específico	No específico	No específico	No específico

F.5.3 Fortalezas complementarias de las plataformas comerciales

Capacidad	Plataformas comerciales	Framework propuesto
Infraestructura administrada y escalable	Fortaleza principal en servicios Cloud y empresariales	Fuera del alcance de la prueba de concepto
Endpoints productivos y despliegue gestionado	Disponibles mediante servicios administrados	Capacidad prevista dentro de la CVPF
Monitoreo continuo de modelos	Disponible de forma nativa o mediante módulos especializados	Estrategia definida; implementación operativa futura
Seguridad, IAM y controles empresariales	Capacidades maduras y configurables	No evaluado como plataforma institucional
AutoML y búsqueda de arquitecturas	Disponibles en varias de las plataformas comparadas	No constituye el foco de la investigación
Soporte empresarial y SLA	Disponible según plan comercial	No aplica a la prueba de concepto académica

Fuente: elaboración propia con base en la documentación oficial de las plataformas consultada al 5 de agosto de 2026.

F.6 Análisis comparativo

El análisis evidencia que las plataformas comerciales ofrecen capacidades robustas para entrenamiento, registro, despliegue, monitoreo y administración del ciclo de vida de modelos de Aprendizaje Automático. En varias de ellas también existen herramientas para preparación de datos, calidad, metadatos, experimentación y explicabilidad.

Sin embargo, estas soluciones se presentan como plataformas de propósito general. La construcción de una arquitectura específica para gestión hídrica, la definición de reglas de gobierno, la homologación semántica, la consolidación de un Dataset Maestro y la incorporación de conocimiento del dominio dependen de la configuración realizada por cada organización.

El Framework desarrollado durante la investigación adopta una perspectiva diferente: integra estos procesos como componentes de una metodología única y especializada. Su diferencial no radica en competir con la infraestructura, escalabilidad o amplitud de servicios de las plataformas comerciales, sino en formalizar un flujo reproducible para el dominio hídrico, desde la adquisición y gobierno de los datos hasta el diagnóstico y la recomendación experimental.

Interpretación equilibrada

El benchmark no establece que el Framework posea más capacidades globales que las plataformas comerciales. Muestra que concentra, dentro de una arquitectura académica especializada, componentes de dominio y trazabilidad que en plataformas generales requieren diseño, integración o configuración adicional.

F.7 Diferenciadores del Framework

- integración gobernada de siete capas oficiales de información relacionadas con la gestión hídrica;
- construcción automática de un Dataset Maestro mediante llaves y reglas homogéneas;
- gobierno del dato incorporado al flujo metodológico de cada capa;
- generación de metadatos, diccionarios, auditorías, indicadores y documentación de salida;
- priorización multicriterio de variables mediante el Índice de Priorización para Machine Learning (IPML);
- articulación entre Catálogo de Conocimiento, IPML, Dataset ML y Diseño Experimental;
- diagnóstico y recomendaciones automáticas asociadas al resultado de cada experimento;
- trazabilidad desde la extracción de información hasta la predicción y la interpretación;
- orientación específica hacia problemas de gestión hídrica y reutilización en nuevos escenarios del dominio.

F.8 Limitaciones de la comparación

Este benchmark corresponde a una comparación funcional documental. No se realizaron pruebas de concepto equivalentes en Azure Machine Learning, Vertex AI, SageMaker, DataRobot o KNIME. En consecuencia, no es posible extraer conclusiones sobre precisión, velocidad, escalabilidad, costos, usabilidad o superioridad tecnológica.

Las plataformas comerciales se actualizan de manera continua y algunas capacidades pueden depender del plan contratado, la región, el tipo de licencia, servicios adicionales o funcionalidades en vista previa. Por esta razón, la matriz debe revisarse antes de utilizarse en futuras publicaciones o decisiones de adquisición.

Las categorías “Config.” y “No específico” no significan que una plataforma sea incapaz de implementar la funcionalidad. Indican que la documentación consultada no presenta un equivalente directo y especializado con la misma definición utilizada por el Framework, o que su implementación requiere componentes adicionales.

F.9 Conclusión

El análisis comparativo muestra que el Framework desarrollado no busca sustituir plataformas comerciales de Machine Learning. Estas plataformas ofrecen capacidades empresariales maduras para infraestructura, entrenamiento, despliegue, monitoreo y gobierno de modelos.

La contribución del Framework es complementaria y metodológica: integra Ingeniería de Datos, Ciencia de Datos y Aprendizaje Automático dentro de un flujo automatizado, trazable y reproducible, especializado en gestión hídrica. Elementos como el Dataset Maestro gobernado, el Catálogo de Conocimiento, el IPML y el ciclo automático de diagnóstico y recomendación constituyen mecanismos propios de la investigación que pueden implementarse sobre infraestructuras comerciales en futuras evoluciones.

En consecuencia, el benchmark permite posicionar el Framework como una arquitectura de dominio que organiza y documenta el ciclo analítico, mientras que las plataformas comerciales pueden actuar como alternativas tecnológicas para escalar, desplegar y operar sus componentes en ambientes institucionales.

Documentos base del anexo

La comparación se sustentó en documentación oficial de los fabricantes. Los siguientes documentos representan la base principal utilizada para verificar las capacidades descritas:

Plataforma	Documentación oficial consultada
Microsoft Azure Machine Learning	Experiment with Azure Machine Learning Azure Machine Learning model monitoring Track experiments and deploy models with MLflow
Google Vertex AI	Introduction to Vertex AI Experiments Introduction to Vertex ML Metadata Tabular Workflows on Vertex AI Vertex AI Model Monitoring schemas
Amazon SageMaker AI	Prepare ML Data with Amazon SageMaker Data Wrangler Amazon SageMaker Experiments Amazon SageMaker Model Registry Amazon SageMaker Model Monitor
DataRobot	Data Quality Assessment Feature Discovery Model Registry and compliance documentation
KNIME	KNIME Analytics Platform Best Practices Guide Integrated Deployment Guide KNIME Business Hub Workflow Validation Guide

Nota metodológica. La inclusión de una plataforma en la matriz no implica aval, certificación ni evaluación contractual. La descripción se limita a capacidades publicadas por cada fabricante y debe verificarse nuevamente antes de cualquier uso institucional.