

ANEXO 9

MODEL FRAMEWORK MACHINE
LEARNING CANVAS

Capa de Validación Profesional del Framework — CVPF

Autores	José Daniel Barreto y Juan Carlos Riatiga Peña
Director	Dr. Jorge Andrick Parra Valencia
Asesora	Dra. Beatriz Eugenia Marín Ospina
Programa	Maestría en Ciencia de Datos
Institución	Universidad Autónoma de Bucaramanga — UNAB
Framework	Framework de Interoperabilidad para la Gestión Hídrica V7
Documento	Framework Machine Learning Canvas · Versión 1.0
Fecha	2026

Control documental

Campo	Definición
Código del documento	CVPF-B-FMLC-V1.0
Tipo de documento	Framework Machine Learning Canvas
Objeto documentado	Framework de Interoperabilidad para la Gestión Hídrica
Versión del Framework	V7
Versión del documento	1.0
Estado	Aprobado para revisión académica
Propietarios académicos	José Daniel Barreto y Juan Carlos Riatiga Peña
Ámbito	Capa de Validación Profesional del Framework (CVPF)
Relación con otros anexos	Complementa la Framework Card del Anexo 8 y las futuras Model Cards de Exp01, Exp01-V3 y Exp04

Naturaleza del documento

El Framework Machine Learning Canvas describe la arquitectura completa y su relación con el problema, los usuarios, los datos, la experimentación, las decisiones y la operación prevista. No sustituye las Model Cards específicas de los modelos. Su incorporación no modifica los resultados originales de la investigación; fortalece la documentación profesional y la alineación con la rúbrica de evaluación.

Contenido del anexo

01	B.0 Introducción	10	B.9 Casos de validación
02	B.1 Identificación	11	B.10 Estrategia de decisión
03	B.2 Problema	12	B.11 Despliegue
04	B.3 Propuesta de valor	13	B.12 Estrategia MLOps
05	B.4 Usuarios y decisiones	14	B.13 Beneficios
06	B.5 Fuentes de información	15	B.14 Riesgos y controles
07	B.6 Ingeniería de Datos	16	B.15 Productos generados
08	B.7 Ciencia de Datos	17	B.16 Contribución y declaración final
09	B.8 Aprendizaje Automático		

B.0 Introducción

El presente Framework Machine Learning Canvas constituye un artefacto documental y visual de la Capa de Validación Profesional del Framework (CVPF). Su propósito es representar, en una estructura integrada, la relación entre el problema de gestión hídrica, la propuesta de valor, los usuarios, las fuentes de información, los procesos de Ingeniería de Datos y Ciencia de Datos, la experimentación predictiva, los costos de decisión, el despliegue previsto y la estrategia de monitoreo.

A diferencia de un Canvas centrado exclusivamente en un modelo, este documento adopta como unidad de análisis el Framework completo, debido a que el aporte principal de la investigación corresponde a la arquitectura interoperable que organiza y automatiza el ciclo analítico. Los modelos LSTM utilizados en Exp01, Exp01-V3 y Exp04 se documentan como componentes experimentales y no como el producto único de la investigación.

El Canvas permite comunicar el ciclo de valor del Framework de manera ejecutiva y verificable. También identifica qué capacidades fueron implementadas y validadas durante la prueba de concepto y cuáles corresponden a la evolución profesional propuesta, especialmente el despliegue web, el monitoreo de deriva y el reentrenamiento.

Declaración de alcance

El Canvas sintetiza y documenta la investigación; no convierte la prueba de concepto en una plataforma productiva ni afirma que las capacidades MLOps estén implementadas. Las capacidades de despliegue, monitoreo y reentrenamiento se presentan como componentes previstos dentro de la CVPF.

Figura B.1. Síntesis visual del Framework Machine Learning Canvas

01 Problema Fragmentación de fuentes, heterogeneidad y procesos manuales.	02 Propuesta de valor Integra y automatiza el ciclo analítico de extremo a extremo.	03 Usuarios Autoridades, empresas, investigadores, universidades y analistas.
04 Fuentes Clima, hidrología, calidad, ONI, hidráulica, percepción y gobernanza.	05 Ingeniería de Datos Extracción, validación, gobierno, homologación e integración.	06 Ciencia de Datos Calidad, EDA, correlación, redundancia, VIF, catálogo e IPML.
07 Machine Learning Dataset ML, diseño experimental, secuencias, LSTM y evaluación.	08 Validación Exp01, Exp01-V3 y Exp04 como evidencia experimental.	09 Decisión FP/FN en clasificación y uso responsable de estimaciones continuas.
10 Despliegue Aplicación web prevista para validación, inferencia y diagnóstico.	11 MLOps Monitoreo, drift, revisión semestral y criterios de reentrenamiento.	12 Valor Dataset Maestro, modelos, predicciones, trazabilidad y evidencia.

Nota. Elaboración propia (2026) a partir de la arquitectura y la evidencia experimental del Framework V7.

B.1 Identificación

Tabla B.1. Identificación del Framework Machine Learning Canvas

Campo	Información
Framework	Framework de Interoperabilidad para la Gestión Hídrica
Versión	Framework V7
Dominio	Gestión hídrica
Objetivo	Automatizar e integrar el ciclo de Ingeniería de Datos, Ciencia de Datos y Aprendizaje Automático
Alcance	Integración, análisis, modelado predictivo, trazabilidad y apoyo analítico a la toma de decisiones
Tipo de Canvas	Canvas arquitectónico del Framework completo
Estado	Artefacto complementario de la CVPF; prueba de concepto validada técnica y metodológicamente
Autores	José Daniel Barreto y Juan Carlos Riatiga Peña
Institución	Universidad Autónoma de Bucaramanga (UNAB)
Fecha	2026

La unidad documentada por este Canvas es la arquitectura metodológica completa. Las decisiones específicas de uso, métricas, riesgos y límites de cada modelo se desarrollarán de manera independiente en las Model Cards correspondientes.

B.2 Problema

Tabla B.2. Problemas abordados por el Framework

Dimensión	Descripción
Problema del dominio	Las organizaciones responsables de la gestión hídrica administran información proveniente de múltiples fuentes oficiales con estructuras, periodicidades, granularidades y niveles de calidad diferentes. Esta fragmentación dificulta la integración y limita la construcción de análisis y modelos predictivos reproducibles.
Problema de Ciencia de Datos	La preparación manual de datos, la selección no documentada de variables y la ejecución independiente de experimentos consumen tiempo, introducen variabilidad metodológica y dificultan la trazabilidad, reproducción y reutilización de los modelos.
Problema de decisión	La dependencia de indicadores aislados puede favorecer interpretaciones parciales del sistema. Se requiere integrar evidencia, contexto y múltiples métricas para apoyar decisiones sin caer en la trampa del indicador.

B.3 Propuesta de valor

El Framework integra automáticamente procesos de Ingeniería de Datos, Ciencia de Datos y Aprendizaje Automático dentro de una arquitectura modular, interoperable y trazable. Esta integración permite transformar datos heterogéneos en productos analíticos y evidencia experimental reutilizable para apoyar el análisis de la gestión hídrica.

Tabla B.3. Dimensiones de la propuesta de valor

Dimensión	Valor aportado
Integración	Conecta fuentes heterogéneas mediante llaves, estructuras y reglas de homologación.
Automatización	Reduce actividades manuales en preparación, análisis, experimentación y documentación.
Reproducibilidad	Conserva configuraciones, metadatos, modelos, métricas, diagnósticos y bitácoras.
Conocimiento del dominio	Incorpora catálogo de conocimiento e IPML antes del entrenamiento.
Adaptabilidad	Permite configurar problemas de clasificación y regresión dentro del mismo flujo.
Apoyo a decisiones	Produce evidencia, diagnósticos y recomendaciones que requieren interpretación experta.

Propuesta de valor sintetizada

El Framework convierte un conjunto de actividades analíticas tradicionalmente fragmentadas en un flujo documentado, auditable y reutilizable, sin sustituir la supervisión humana ni las decisiones técnicas del dominio.

B.4 Usuarios y decisiones

Tabla B.4. Usuarios y necesidades de información

Elemento	Definición
Usuarios primarios	Autoridades ambientales; empresas de servicios públicos; investigadores; universidades; analistas de datos.
Usuarios secundarios	Tomadores de decisiones; entidades gubernamentales; equipos de planeación; comunidad como beneficiaria indirecta.
Necesidad principal	Acceder a información integrada, trazable y analíticamente preparada para caracterizar variables, evaluar escenarios y orientar análisis.
Decisiones apoyadas	Priorización de análisis; definición de nuevas mediciones; evaluación de tendencias; revisión de condiciones de riesgo; planificación de nuevas configuraciones experimentales.
Responsabilidad final	La decisión permanece bajo responsabilidad de profesionales, entidades y especialistas del dominio.

B.5 Fuentes de información

Las fuentes se describen según el mecanismo de acceso y la información efectivamente integrada por los notebooks. La institución originadora debe conservarse en los metadatos de cada capa cuando se encuentre explícitamente identificada.

Tabla B.5. Ecosistema de información del Framework

Fuente consultada	Tipo	Información integrada
NASA POWER	Climática	Precipitación, temperatura, humedad, radiación y viento
NOAA	Variabilidad climática	Índice Oceánico de El Niño (ONI) y clasificación ENSO
Datos Abiertos Colombia / registros hidrológicos	Hidrología	Observaciones hidrológicas y datos de estaciones
Datos Abiertos Colombia / fuentes de calidad del agua	Calidad del agua	Parámetros físicoquímicos y registros de calidad
Repositorio público de información hidráulica	Hidráulica	Volumen Útil Diario de Masa y variables operacionales
Datos Abiertos Colombia	Percepción e IRCA	IRCA, nivel de riesgo y datos para consumo humano
Datos Abiertos de Cundinamarca	Gobernanza	Indicadores institucionales, demográficos y de servicios

Gobierno de las fuentes

Cada capa conserva fuente, versión, cobertura, responsable, fecha de ETL, diccionario, auditoría e indicadores. La disponibilidad desigual de información constituye una limitación documentada y no debe ocultarse mediante la integración.

B.6 Ingeniería de Datos

El componente de Ingeniería de Datos transforma las fuentes heterogéneas en capas gobernadas y en un Dataset Maestro que actúa como fuente integrada para las etapas posteriores.

Tabla B.6. Entrada, procesos y salida de Ingeniería de Datos

Etapa	Función
Entrada	APIs, archivos, repositorios públicos y datasets con diferentes estructuras y granularidades.
Extracción	Consulta y descarga de las fuentes definidas para cada capa.
Validación	Dimensiones, columnas, tipos, cobertura temporal, nulos, duplicados e integridad.
Estandarización	Normalización de nombres, tipos, fechas, nodos, identificadores y orden de campos.
Gobierno	Fecha y hora ETL, versión, responsable, estado del registro, hash y metadatos.
Homologación	Construcción de llaves comunes de Nodo, Fecha, Año y Mes.
Integración	Incorporación incremental de las siete capas dentro de una estructura común.
Salida	Dataset Maestro, capas documentadas, auditorías, indicadores, diccionarios y README.

Figura B.2. Flujo de Ingeniería de Datos



Nota. El flujo es reproducible y conserva evidencia de las transformaciones aplicadas.

B.7 Ciencia de Datos

El Framework no inicia directamente el entrenamiento. Antes de modelar, caracteriza el Dataset Maestro, examina su calidad y relaciones, incorpora conocimiento del dominio y prioriza variables mediante criterios explícitos.

Tabla B.7. Procesos automáticos de Ciencia de Datos

Proceso	Resultado
Perfilamiento	Dimensiones, tipos, memoria, cobertura, valores únicos y estructura general.
Calidad	Compleitud, duplicados, nulos, consistencia y cobertura por variable.
EDA	Estadística descriptiva, distribuciones, asimetría, atípicos y comportamiento temporal.
Correlaciones	Matrices Pearson y Spearman para identificar relaciones lineales y monotónicas.
Redundancia	Índice, ranking y red de variables con relaciones fuertes.
Multicolinealidad	Factor de Inflación de la Varianza (VIF) y diagnóstico estructural.
Catálogo de conocimiento	Clasificación temática, variables del dominio y relaciones semánticas.
IPML	Integración de conocimiento, calidad, redundancia y multicolinealidad para priorizar variables.
Salida	Variables seleccionadas, pendientes o excluidas y Dataset preparado para Machine Learning.

Principio metodológico

La selección de variables no depende únicamente de correlaciones o importancia algorítmica. El IPML conserva una decisión multicriterio documentada y reproducible antes del modelado.

B.8 Aprendizaje Automático

El componente de Aprendizaje Automático consume las variables priorizadas, recupera la configuración del catálogo experimental y ejecuta un flujo adaptado al tipo de problema definido.

Figura B.3. Flujo de Aprendizaje Automático

Variables IPML	Dataset ML	Diseño experimental	Secuencias	Tensores	LSTM	Evaluación	Interpretación
----------------	------------	---------------------	------------	----------	------	------------	----------------

Tabla B.8. Componentes del flujo predictivo

Componente	Función
Dataset ML	Selección y validación de variables, nulos, duplicados y formatos.
Diseño experimental	Objetivo, variable objetivo, predictores, ventana, horizonte, modelo, métricas y estado.
Preparación temporal	Construcción de secuencias con ventana 12 y horizonte 1.
Transformación	StandardScaler o RobustScaler según la configuración y el diagnóstico de datos.
Modelado	Arquitectura LSTM, entrenamiento y Early Stopping.
Evaluación	Métricas diferenciadas para clasificación y regresión.
Diagnóstico	Interpretación conjunta de métricas y determinación del estado del modelo.
Recomendaciones	Estrategias de balanceo, ajuste de umbral, hiperparámetros, variables y modelos alternativos.
Predicción	Recuperación del modelo, scaler y metadatos para generar nuevas estimaciones.

B.9 Casos de validación

El Framework fue evaluado mediante dos casos predictivos representativos y una iteración de optimización. Estas ejecuciones muestran la capacidad de adaptar el flujo a problemas de clasificación y regresión.

Tabla B.9. Evidencia experimental utilizada en el Canvas

Ejecución	Tipo	Objetivo	Función	Evidencia
Exp01	Clasificación	IRCA	Experimento inicial	Accuracy 84,62%; Precision, Recall y F1 iguales a 0. Diagnóstico: modelo no apto para detectar el objetivo.
Exp01-V3	Clasificación	IRCA	Iteración con SMOTE	Accuracy 92,26%; Precision 0,5645; Recall 0,7292; F1 0,6364. Capacidad predictiva parcial.
Exp04	Regresión	Volumen Útil Diario de Masa	Caso de regresión	MAE 0,0824; RMSE 0,1470; MAPE 23,89%; R^2 0,7225. Modelo aceptable dentro de la prueba de concepto.

Interpretación

Exp01 evidencia la trampa del indicador: una Accuracy elevada no implica capacidad para detectar la clase de interés. Exp01-V3 demuestra el ciclo diagnóstico–recomendación–optimización. Exp04 confirma la adaptación del Framework a una variable objetivo continua.

B.10 Estrategia de decisión

Las predicciones se conciben como evidencia de apoyo y no como decisiones automáticas. La estrategia debe considerar la naturaleza del error, el contexto operativo y la supervisión de especialistas.

Tabla B.10. Costos cualitativos del error en Exp01

Error	Descripción	Impacto potencial	Prioridad
Falso negativo	No detectar oportunamente un posible deterioro asociado al IRCA.	Retraso en acciones preventivas, mayor exposición al riesgo sanitario y aumento potencial de costos de mitigación.	Mayor
Falso positivo	Generar una alerta preventiva cuando el evento no ocurre.	Inspecciones adicionales, movilización de recursos y costos operativos moderados.	Menor

En clasificación, el costo potencial de un falso negativo es superior al de un falso positivo. Por esta razón, Recall, F1-Score y Balanced Accuracy deben analizarse junto con Accuracy. La selección del umbral debe buscar capacidad de detección sin producir un volumen operativo inaceptable de falsas alertas.

Tabla B.11. Criterios de uso de Exp04

Elemento	Criterio
Uso	Apoyo al análisis de tendencias y comportamiento del Volumen Útil Diario de Masa.
Sobreestimación	Puede inducir una interpretación optimista de la disponibilidad; requiere contraste con mediciones y contexto operativo.
Subestimación	Puede favorecer decisiones excesivamente conservadoras o asignaciones ineficientes.
Condición	La predicción no sustituye mediciones de campo, registros oficiales ni decisiones regulatorias.

B.11 Despliegue

El despliegue se incorpora como capacidad complementaria de la CVPF. La arquitectura prevista permite demostrar inferencia con datos nuevos, validación de entradas, tiempo de respuesta, diagnóstico y manejo de excepciones, sin afirmar que la prueba de concepto ya opera como plataforma institucional productiva.

Figura B.4. Arquitectura funcional prevista para la demostración

Usuario	Aplicación web	Validación	Framework	Modelo LSTM	Predicción	Diagnóstico	Recomendación
---------	----------------	------------	-----------	-------------	------------	-------------	---------------

Tabla B.12. Componentes del despliegue previsto

Componente	Descripción	Estado
Interfaz	Aplicación Streamlit para seleccionar experimento, cargar CSV y visualizar resultados.	Prevista en la CVPF
Validación de entrada	Columnas requeridas, tipos de datos, nulos, longitud temporal y orden de variables.	Prevista
Inferencia	Carga del modelo .keras, scaler, metadatos y generación de predicción.	Componentes disponibles; interfaz en desarrollo
Manejo de errores	Mensajes controlados ante estructura inválida, datos insuficientes o archivos incompatibles.	Previsto
Latencia	Registro del tiempo requerido para cargar, transformar y predecir.	Previsto
Salida	Predicción, diagnóstico, advertencias de uso y archivo descargable.	Previsto

Prueba en vivo

La demostración deberá incluir un caso válido y un caso de borde o error. La aplicación web es una interfaz de validación funcional; no representa todavía una arquitectura de producción con disponibilidad garantizada.

B.12 Estrategia MLOps

La estrategia MLOps se presenta como diseño de evolución. Su propósito es definir qué debería observarse después del despliegue y bajo qué condiciones se revisaría o reentrenaría un modelo.

Tabla B.13. Estrategia de monitoreo propuesta

Dimensión	Indicadores	Frecuencia
Calidad de entrada	Columnas, tipos, rangos, nulos, cobertura y frecuencia de actualización.	Cada inferencia / carga
Clasificación	Accuracy, Precision, Recall, F1 y Balanced Accuracy.	Seguimiento periódico
Regresión	MAE, RMSE, MAPE y R ² .	Seguimiento periódico
Data drift	Cambios en la distribución de variables predictoras y variable objetivo.	Revisión semestral o ante alertas
Concept drift	Pérdida de relación entre predictores y objetivo.	Cuando disminuya el desempeño
Operación	Tiempo de inferencia, errores de carga y disponibilidad de la interfaz.	Durante la operación

Tabla B.14. Criterios de revisión y reentrenamiento

Condición	Acción propuesta
Ingreso de nuevos datos	Revisar cobertura, representatividad y compatibilidad antes de incorporar la nueva información.
Degradación de métricas	Reentrenar cuando el desempeño disminuya de forma sostenida frente a la línea base documentada.
Data drift	Evaluar reentrenamiento si las distribuciones cambian de manera relevante.
Concept drift	Revisar variables, ventana, horizonte, arquitectura y objetivo del experimento.
Cambios de fuente	Actualizar metadatos, validaciones, diccionarios y reglas de homologación.
Frecuencia sugerida	Revisión semestral, sin perjuicio de revisiones extraordinarias ante cambios relevantes.

B.13 Beneficios

Tabla B.15. Beneficios esperados del Framework

Beneficio	Descripción
Reducción de tiempos	Reutiliza módulos y evita repetir manualmente actividades de preparación y documentación.
Interoperabilidad	Integra datos con estructuras y granularidades distintas dentro de un Dataset Maestro.
Reproducibilidad	Conserva configuración, parámetros, transformaciones, modelos, métricas y evidencia.
Calidad metodológica	Introduce controles antes del modelado y evita depender de una única métrica.
Reutilización	Permite incorporar nuevas fuentes, variables, experimentos y modelos de forma modular.
Aprendizaje experimental	Convierte resultados, diagnósticos y recomendaciones en insumos para nuevas iteraciones.
Apoyo a decisiones	Entrega información organizada y trazable para análisis por especialistas y entidades.

B.14 Riesgos y controles

Tabla B.16. Riesgos del Canvas y controles propuestos

Riesgo	Implicación	Control
Calidad insuficiente	Datos incompletos, inconsistentes o desactualizados.	Auditorías, indicadores, validación estructural y documentación de cobertura.
Pérdida de fuentes	Interrupción de APIs, archivos o repositorios.	Registro de fuente, versiones, respaldos y procedimientos alternativos.
Cambios temporales	Data drift o concept drift.	Monitoreo, comparación con línea base y revisión semestral.
Desbalance	Baja detección de eventos positivos.	Métricas múltiples, SMOTE, class_weight y revisión de umbral.
Uso fuera del dominio	Aplicación en otros territorios sin validación.	Restricciones explícitas y recalibración obligatoria.
Interpretación incorrecta	Tomar predicciones como decisiones definitivas.	Advertencias, Model Cards, supervisión humana y validación experta.
Sesgo de cobertura	Representación desigual entre regiones o periodos.	Documentar cobertura, limitaciones y representatividad de las fuentes.
Fairness	El modelo no clasifica personas, pero la desigualdad informativa territorial puede afectar la utilidad.	Evaluar disponibilidad y calidad diferencial por nodo, periodo y territorio.

Supervisión humana

El Framework organiza evidencia para apoyar análisis. Ningún resultado debe activar de manera autónoma alertas oficiales, decisiones sanitarias, acciones regulatorias o intervenciones sobre infraestructura.

B.15 Productos generados

Los productos generados constituyen evidencia verificable del flujo y permiten reconstruir la relación entre datos, experimentos, modelos y resultados.

Tabla B.17. Productos del Framework y valor documental

Etapa	Productos
Ingeniería de Datos	Capas gobernadas, Dataset Maestro, metadatos, diccionarios, auditorías, indicadores, hashes y README.
Ciencia de Datos	Perfilamiento, reportes EDA, Pearson, Spearman, redundancia, VIF, catálogo de conocimiento e IPML.
Preparación ML	Dataset ML, secuencias, tensores, scaler, metadata de secuencias y registro de preparación.
Diseño experimental	Catálogo, configuraciones, variables, métricas, criterios y estado de experimentos.
Modelado	Modelos .keras, historial, hiperparámetros, tiempos y métricas.
Evaluación	Diagnósticos, recomendaciones, interpretación, predicciones y metadata de predicción.
Trazabilidad	Registro de experimento y bitácora maestra.
CVPF	Framework Card, Framework Machine Learning Canvas, futuras Model Cards, validación estadística, aplicación y manual de despliegue.

B.16 Contribución y declaración final

El principal aporte del Framework consiste en integrar, dentro de una única arquitectura interoperable, procesos que tradicionalmente se ejecutan de manera independiente en proyectos de Ciencia de Datos. Esta integración articula fuentes, gobierno de datos, análisis exploratorio, conocimiento del dominio, priorización de variables, diseño experimental, modelado, evaluación, diagnóstico, recomendaciones y trazabilidad.

El Framework Machine Learning Canvas representa esta arquitectura como un ciclo de valor completo. Su diferenciación respecto a un Canvas tradicional radica en que la unidad de análisis no es únicamente el modelo, sino la plataforma metodológica que produce y administra los modelos experimentales. Esta adaptación se presenta como un artefacto metodológico complementario de la CVPF y no como un estándar universal previamente validado.

La construcción del Canvas fortalece la comunicación entre las dimensiones técnica, científica, operativa y de decisión del proyecto. También permite identificar de forma explícita las capacidades implementadas, las limitaciones actuales y los elementos requeridos para una futura evolución hacia despliegue y MLOps.

Declaración final

El Framework es el producto principal de la investigación; los modelos son componentes experimentales; y el Framework Machine Learning Canvas sintetiza cómo los datos, procesos,

decisiones y capacidades previstas se relacionan dentro de una arquitectura interoperable, reproducible y orientada al apoyo analítico de la gestión hídrica.